

祖先重建的数学

从概率、树上剪枝到 DEC、SSE 与模拟训练

中文独立小册子，版本 1.0 / 资料检索截止：2026-08-10

目录

数学插章：把核心公式真正看懂

- 小册子怎样读
- 最低先修知识
- 学完后应能做到
- M.1 一张统一符号表
- M.2 概率、似然和后验不是三个近义词
 - M.2.1 概率：模型给未来数据多少可能性
 - M.2.2 似然：数据已经固定，反过来比较参数
 - M.2.3 后验：数据更新了先验认识
 - M.2.4 一句话自检
- M.3 为什么速率矩阵能描述枝上的变化
 - M.3.1 先从“等待多久”开始
 - M.3.2 极短时间中的事件表
 - M.3.3 从瞬时速率到整条枝的转移概率
 - M.3.4 两状态模型的可手算例子
- M.4 树上剪枝：为什么不用枚举所有祖先组合
 - M.4.1 向下信息：一个节点以下的数据
 - M.4.2 三个末端的完整手算
 - M.4.3 为什么节点向下似然不能直接当节点后验
 - M.4.4 计算量和数值缩放
- M.5 边缘节点、联合节点和完整历史是三种答案
 - M.5.1 边缘后验：只问一个节点
 - M.5.2 联合重建：问所有节点同时是什么
 - M.5.3 随机性状历史：问整条枝上发生过什么
- M.6 连续性状：均值、方差和共同祖先怎样进入似然
 - M.6.1 布朗运动不是“性状一直向上漂”
 - M.6.2 为什么亲缘近的物种不独立
 - M.6.3 多元正态似然应怎样读
 - M.6.4 两个后代怎样加权祖先值
 - M.6.5 OU 模型增加了什么
- M.7 DEC 数学：范围状态、枝上变化和分支继承
 - M.7.1 范围为什么是一个状态
 - M.7.2 DEC 的枝上速率矩阵
 - M.7.3 分支事件为何需要另一个张量

- M.7.4 分支事件后验怎样合并全树信息
- M.8 SSE 数学：为什么灭绝侧枝会变成常微分方程
 - M.8.1 固定树方法缺失了哪一层随机过程
 - M.8.2 在一个极短时间内列出全部事件
 - M.8.3 观测子树似然函数 $D_i(t)$
 - M.8.4 现在时边界条件
 - M.8.5 简单 BiSSE 是上式的特例
 - M.8.6 ODE 求解器到底近似了什么
- M.9 参数不确定性、模型比较和模型平均
 - M.9.1 点估计为何不够
 - M.9.2 AIC 在权衡什么
 - M.9.3 模型平均比“选冠军”多做了一步
 - M.9.4 模型比较不等于模型检验
- M.10 不可辨识性：不同机制为什么会产生相似结果
 - M.10.1 三类常见补偿
 - M.10.2 四个诊断信号
 - M.10.3 一个应始终报告的分层结果
- M.11 一张公式阅读地图
- M.12 手算练习与答案
 - 练习 1：速率与等待时间
 - 练习 2：去向概率
 - 练习 3：节点似然与节点后验
 - 练习 4：范围状态数
 - 练习 5：DEC 局部消失
 - 练习 6：SSE 的幽灵侧枝
 - 练习 7：OU 半衰期
 - 练习 8：AIC 权重
- M.13 哪些数学细节可以暂时不学
- M.14 模拟训练怎样近似祖先状态概率
- 本章小结
- 精选延伸阅读
- 最后一页：只记住这八句话

数学插章：把核心公式真正看懂

这本小册子不要求读者先成为数学家。目标是让你能把公式翻译成生物学问题，知道软件对什么求和、哪些量仍被固定，以及一个输出为什么不能支持过强结论。

小册子怎样读

全册围绕一条共同计算链展开：

事件率 → 枝上传播 → 节点合并 → 消去隐藏量 → 似然或后验.

你的目标	建议先读	暂时可以后读
看懂普通离散性状重建	M.1–M.5	M.7–M.10、M.14
看懂连续性状 BM/OU	M.1、M.2、M.6、M.9	M.7、M.8
看懂 BioGeoBEARS/DEC	M.1–M.5、M.7、M.9	M.6、M.8、M.14
看懂 PhyBEARS/SSE	M.1–M.5、M.7、M.8、M.10	M.6、M.14
开发数值引擎	全读，并实际复算 M.4、M.7、M.8	无
了解模拟式深度学习	M.2、M.5、M.10、M.14	M.6–M.8

第一次阅读时，不必记住全部公式。每遇到一个公式，只回答五个问题：

1. 它描述节点、枝上历史，还是树的生成？
2. 竖线右边固定了哪些条件？
3. 哪些隐藏状态被求和或积分掉了？
4. 这个量是概率、似然、无量纲权重，还是每单位时间速率？
5. 它是否已经归一化为和等于 1 的后验？

最低先修知识

读者只需熟悉四则运算、指数和对数的直觉，并知道“矩阵是一张按行列排列的数表”。书中会直接解释条件概率、正态分布、矩阵指数、常微分方程和 softmax 在模型中承担的任务，不要求先掌握证明。

学完后应能做到

- 解释为什么一条枝两端状态相同，不代表枝上没有变化；
- 手算一棵三末端树的条件似然和节点后验；
- 说明 DEC 的局部消失率为何不等于整条谱系灭绝率；
- 从短时间事件表推回 SSE 的 $E(t)$ 和 $D(t)$ 方程；
- 解释布朗运动协方差与 OU 半衰期；
- 区分参数点估计、节点后验、随机历史和模型平均；
- 判断一个神经网络概率究竟依赖哪套训练模拟分布。

本章不增加一种新模型，而是把前后各章共用的数学骨架拆开。目标不是训练读者手工求矩阵指数，也不是证明常微分方程求解器为什么收敛，而是让读者能够独立回答四个问题：

1. 公式中的每个量代表什么生物学对象？
2. 一个概率究竟以什么为条件，又对什么求和了？
3. 软件为什么要用树上剪枝、矩阵指数或常微分方程？
4. 输出中的似然、节点概率、事件次数和参数区间分别能说明什么？

如果一个公式暂时看不懂，先不要追着每个下标跑。先用一句话说清它在做什么，再检查单位、条件和归一化。绝大多数错误都能在这三步中暴露。

M.1 一张统一符号表

不同论文经常用同一个字母表示不同东西。下表是本书统一采用的记号；阅读原论文时，应先把作者的记号翻译成这一套，而不是死记字母。

符号	本书中的含义	是观测、隐藏量还是参数
D	全部观测数据，如末端性状、现生分布、序列或化石	观测
T	带枝长的系统发育树	可固定，也可作为待估对象
X_v	节点 v 的祖先状态	隐藏量
H	一条完整演化历史，包括枝上何时发生了什么变化	隐藏量
θ	某个模型的全部参数	参数
M	模型结构，如 Mk、DEC、BiSSE 或 OU	模型
Q	连续时间马尔可夫链的瞬时速率矩阵	参数的函数
$P(t)$	长度为 t 的枝上的状态转移概率矩阵	由 Q 和 t 决定
π_i	根处于状态 i 的先验概率或根频率	模型设定或参数
$L_v(i)$	已知节点 v 是 i 时，其下方数据的条件似然	中间计算量
$O_v(i)$	节点 v 上方与旁支数据对状态 i 的似然信息	中间计算量
$C_{i,j,k}$	祖先范围 i 分成女儿范围 j, k 的条件权重或概率	固定树分支规则
$\lambda_{i,j,k}$	状态 i 的谱系以速率分化成状态 j, k 两支	每单位时间事件率
μ_i	状态 i 的整条谱系灭绝率	每单位时间事件率
ρ_i	状态 i 的现生谱系被采样的概率	取样参数
$E_i(t)$	从距今 t 的一个状态 i 谱系出发，最终没有已采样后代的概率	隐藏谱系被求和后的概率

符号	本书中的含义	是观测、隐藏量还是参数
$D_i(t)$	从距今 t 的一个状态 i 谱系出发，产生当前已观测子树的条件似然	沿时间传播的似然
σ^2	布朗运动每单位枝长积累的性状方差	连续性状参数
α	OU 模型向长期中心回归的强度	连续性状参数
ϑ	OU 模型的长期中心；特意不用 θ ，以免与参数向量混淆	连续性状参数

两个特别容易混淆的记号必须单独强调：

- $C_{i,j,k}$ 通常是已经发生了一个观察到的分支事件之后，各种范围继承方式的相对概率。它没有“每百万年”的单位。
- $\lambda_{i,j,k}$ 是谱系在尚未观察的连续时间里发生分化的速率。它的单位是“每条谱系、每单位时间”。

这不是字母大小写的差别，而是两个不同的概率对象。

M.2 概率、似然和后验不是三个近义词

M.2.1 概率：模型给未来数据多少可能性

给定参数 θ ，数据出现的概率写成：

$$P(D \mid \theta, M).$$

竖线右边是条件，意思是“假定模型和参数已经知道”。例如已知一条枝的变化速率和长度，计算末端从红色变成蓝色的概率。

M.2.2 似然：数据已经固定，反过来比较参数

同一个表达式被看成参数的函数时叫似然：

$$\mathcal{L}(\theta; D, M) = P(D \mid \theta, M).$$

右边数值没有改变，问题方向变了。概率问“这个参数会生成什么数据”，似然问“哪组参数更能解释已经看到的数据”。因此， $\mathcal{L}(\theta)$ 不需要对所有 θ 加起来等于 1。

最大似然估计是：

$$\hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta; D, M) = \arg \max_{\theta} \log \mathcal{L}(\theta; D, M).$$

取对数不会改变最大值的位置，却把大量概率的乘法变成加法，也减轻计算机下溢。

M.2.3 后验：数据更新了先验认识

贝叶斯公式把似然与先验结合：

$$P(\theta \mid D, M) = \frac{P(D \mid \theta, M)P(\theta \mid M)}{P(D \mid M)}.$$

其中

$$P(D \mid M) = \int P(D \mid \theta, M)P(\theta \mid M) d\theta$$

称为边际似然：它把参数不确定性积分掉。只比较同一模型内不同参数时，常写成：

$$P(\theta \mid D, M) \propto P(D \mid \theta, M)P(\theta \mid M).$$

同理，祖先状态的后验不是单独看一个节点向下的似然，而是：

$$P(X_v = i \mid D, T, M) = \int P(X_v = i \mid D, T, \theta, M)P(\theta \mid D, T, M) d\theta.$$

如果软件把 θ 固定在最大似然估计 $\hat{\theta}$ ，得到的是“参数固定后的节点概率”；如果还对参数、树和模型积分，才是更完整的不确定性传播。

M.2.4 一句话自检

看到一个数时问：

- 它是“模型生成数据”的概率吗？

- 它是“固定数据后比较参数”的似然吗？
- 还是“数据更新先验后”的后验概率？

节点饼图一般是第三类；优化器报告的 `lnL` 是第二类；随机模拟生成一次结果用的是第一类。

M.3 为什么速率矩阵能描述枝上的变化

M.3.1 先从“等待多久”开始

设谱系当前处于状态 i ，从 i 离开的总速率是：

$$r_i = \sum_{j \neq i} q_{ij} = -q_{ii}.$$

连续时间马尔可夫链假定等待时间服从指数分布：

$$P(\text{到时间 } t \text{ 仍未离开 } i) = e^{-r_i t}.$$

因此平均等待时间是 $1/r_i$ 。一旦发生离开，下一状态为 j 的条件概率是：

$$P(i \rightarrow j \mid \text{已经离开 } i) = \frac{q_{ij}}{r_i}.$$

这里自然分成两件事：总速率决定“等多久”，各 q_{ij} 的比例决定“去哪儿”。

M.3.2 极短时间中的事件表

在很短的 Δt 内：

$$P(i \rightarrow j) = q_{ij}\Delta t + o(\Delta t), \quad j \neq i,$$

$$P(i \rightarrow i) = 1 - r_i\Delta t + o(\Delta t).$$

$o(\Delta t)$ 表示比 Δt 更快趋近于 0 的高阶小量。直觉上，一段足够短的时间内发生一次事件的概率与时长成正比，发生两次以上的概率小得多。

把所有状态排成矩阵，就得到：

$$Q = \begin{pmatrix} -\sum_{j \neq 1} q_{1j} & q_{12} & \cdots \\ q_{21} & -\sum_{j \neq 2} q_{2j} & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

每一行和为 0，保证所有去向的概率和为 1。

M.3.3 从瞬时速率到整条枝的转移概率

长度为 t 的枝上允许发生 0、1、2 次乃至更多次变化。把所有可能次数和时刻都求和，得到：

$$P(t) = e^{Qt}.$$

矩阵指数不是把每个元素分别取指数，而是：

$$e^{Qt} = I + Qt + \frac{(Qt)^2}{2!} + \frac{(Qt)^3}{3!} + \cdots.$$

各次幂可以直观地理解为对越来越多次中间变化的贡献求和。实际软件会用稳定的矩阵算法，不需要按这个无穷级数手算。

它还满足：

$$P(t_1 + t_2) = P(t_1)P(t_2).$$

所以一条跨越多个时间层的枝可以分段传播。若从祖先向末端依次经历旧环境 Q_1 和新环境 Q_2 ，采用行向量约定时：

$$P_{\text{整枝}} = e^{Q_1 t_1} e^{Q_2 t_2}.$$

顺序不能交换；两个矩阵一般不满足 $AB = BA$ 。

M.3.4 两状态模型的可手算例子

红、蓝两状态以相同速率 q 互换：

$$Q = \begin{pmatrix} -q & q \\ q & -q \end{pmatrix}.$$

转移概率有简单闭式：

$$P_{\text{相同}}(t) = \frac{1 + e^{-2qt}}{2}, \quad P_{\text{改变}}(t) = \frac{1 - e^{-2qt}}{2}.$$

令 $q = 0.2/\text{百万年}$, $t = 1.5$ 百万年, 则 $2qt = 0.6$:

$$P_{\text{相同}} \approx 0.7744, \quad P_{\text{改变}} \approx 0.2256.$$

这也说明速率和枝长必须配套。 qt 没有单位；若把枝长从“百万年”改成“年”却不换算速率，模型就完全变了。

M.4 树上剪枝：为什么不用枚举所有祖先组合

假设树上每个节点有 K 种可能状态。若有 m 个内部节点，直接枚举需要考虑 K^m 种祖先组合，很快就不可计算。剪枝算法利用“给定父状态后，左右子树条件独立”这一结构，把指数级求和拆成局部递推。Felsenstein (1981) 奠定了这类系统发育似然计算的通用形式。

M.4.1 向下信息：一个节点以下的数据

定义：

$$L_v(i) = P(D_{\downarrow v} \mid X_v = i),$$

其中 $D_{\downarrow v}$ 是节点 v 以下所有末端数据。若 v 有左右两个子节点 a, b ，则：

$$L_v(i) = \left[\sum_j P_{ij}(t_a) L_a(j) \right] \left[\sum_k P_{ik}(t_b) L_b(k) \right].$$

方括号的意思分别是：“如果父节点为 i ，把该子枝末端所有可能状态求和”。左右两项相乘，是因为给定父状态后两棵子树独立。

到根节点 r 后：

$$\mathcal{L}(D \mid T, \theta, M) = \sum_i \pi_i L_r(i).$$

M.4.2 三个末端的完整手算

考虑树 $((甲,乙),丙)$ ，状态只有红、蓝。所有枝上“保持原状态”的概率为 0.8，“改变状态”的概率为 0.2。末端观测为：

末端	观测状态
甲	红
乙	蓝
丙	蓝

甲、乙的共同祖先记作 v 。若 v 是红：

$$L_v(\text{红}) = 0.8 \times 0.2 = 0.16.$$

若 v 是蓝：

$$L_v(\text{蓝}) = 0.2 \times 0.8 = 0.16.$$

只看 v 以下的数据，红蓝似乎各占一半。再把这条子树传到根：

$$\sum_j P_{\text{红},j} L_v(j) = 0.8 \times 0.16 + 0.2 \times 0.16 = 0.16,$$

根为蓝时也是 0.16。丙为蓝，因此根的两个条件似然为：

$$L_r(\text{红}) = 0.16 \times 0.2 = 0.032,$$

$$L_r(\text{蓝}) = 0.16 \times 0.8 = 0.128.$$

若根先验红蓝各 0.5，整棵树的似然是：

$$\mathcal{L} = 0.5 \times 0.032 + 0.5 \times 0.128 = 0.08.$$

根状态后验需要归一化：

$$P(X_r = \text{红} \mid D) = \frac{0.5 \times 0.032}{0.08} = 0.2,$$

$$P(X_r = \text{蓝} \mid D) = 0.8.$$

这一步清楚地区分了未归一化似然贡献与后验概率。

M.4.3 为什么节点向下似然不能直接当节点后验

节点 v 的后验还要吸收根、丙和连接枝带来的信息。定义上方信息：

$$O_v(i) = P(D_{\text{不在 } v \text{ 下方}}, X_v = i),$$

则：

$$P(X_v = i | D) \propto L_v(i)O_v(i).$$

在上例中：

$$O_v(\text{红}) = 0.5 \times 0.2 \times 0.8 + 0.5 \times 0.8 \times 0.2 = 0.16,$$

$$O_v(\text{蓝}) = 0.5 \times 0.2 \times 0.2 + 0.5 \times 0.8 \times 0.8 = 0.34.$$

乘以下方似然 0.16 并归一化：

$$P(X_v = \text{红} | D) = 0.32, \quad P(X_v = \text{蓝} | D) = 0.68.$$

如果把 $L_v(\text{红}) = L_v(\text{蓝})$ 直接归一化，就会错误地报告 0.5 对 0.5。这个例子就是为什么边缘祖先后验需要“向下加向上”两遍传播。

M.4.4 计算量和数值缩放

普通稠密转移矩阵下，每条枝需要约 K^2 次运算，整棵树约为：

$$O(EK^2),$$

其中 E 是枝数。存储每个节点的状态向量约为 $O(NK)$ 。范围模型的 K 可随地区数指数增长，因此地区状态空间往往比末端物种数更先成为瓶颈。

树很大时，许多小概率连乘会下溢成 0。常见处理是在每个节点用：

$$c_v = \sum_i L_v(i), \quad \tilde{L}_v(i) = L_v(i)/c_v$$

进行缩放，并把 $\log c_v$ 累加回总对数似然。缩放只改变数值表示，不应改变概率模型。

M.5 边缘节点、联合节点和完整历史是三种答案

M.5.1 边缘后验：只问一个节点

$$P(X_v = i | D) = \sum_{X_{-v}} P(X_v = i, X_{-v} | D).$$

这里 X_{-v} 表示其余所有节点状态。也就是说，每个节点的饼图都把其他节点状态求和消去了。因此，把每个节点各自概率最大的颜色拼起来，不保证得到一套联合概率最大的祖先配置。

M.5.2 联合重建：问所有节点同时是什么

$$\hat{X}_{\text{joint}} = \arg \max_X P(X | D).$$

这是一个整体最优化问题。它仍然只指定节点，不指定枝上变化发生的时间和次数。

M.5.3 随机性状历史：问整条枝上发生过什么

完整历史后验是：

$$P(H | D, T, \theta, M) \propto P(D | H)P(H | T, \theta, M).$$

随机映射从这个分布抽取许多条历史。事件次数、占据时间和变化顺序都应在这些完整历史上统计，而不是只比较枝两端。

沿用两状态例子， $q = 0.2$ 、 $t = 1.5$ 。枝两端相同时，完全没有变化的概率是：

$$P(N = 0) = e^{-qt} = e^{-0.3} \approx 0.7408.$$

两端相同的总概率却是 0.7744，因为还包括 2、4、6 次变化。因此：

$$P(N = 0 | \text{两端相同}) = \frac{0.7408}{0.7744} \approx 0.9566.$$

也就是说，即使枝两端颜色一样，仍有约 4.34% 的条件概率来自发生过两次及以上、最终又回到原状态的历史。高速率或长枝时，这部分会更大。

M.6 连续性状：均值、方差和共同祖先怎样进入似然

M.6.1 布朗运动不是“性状一直向上漂”

布朗运动写成：

$$dX_t = \sigma dW_t.$$

在长度为 t 的枝上：

$$X_t - X_0 \sim \mathcal{N}(0, \sigma^2 t).$$

平均变化为 0，但变化的不确定性随枝长线性增加。它描述的是无方向的累积波动，不是确定的直线趋势。

M.6.2 为什么亲缘近的物种不独立

两个末端 i, j 从根到它们最近共同祖先之前共享同一段随机历史。若共享枝长为 t_{ij} ，则：

$$\text{Cov}(X_i, X_j) = \sigma^2 t_{ij}.$$

把所有末端排在一起：

$$\mathbf{x} \sim \mathcal{N}(\mu \mathbf{1}, \mathbf{V}), \quad V_{ij} = \sigma^2 t_{ij}.$$

这就是系统发育比较方法中协方差矩阵的来源：近缘物种共享历史较长，残差天然相关。

M.6.3 多元正态似然应怎样读

$$\log \mathcal{L} = -\frac{1}{2} \left[(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}) + \log |\mathbf{V}| + n \log(2\pi) \right].$$

不要被矩阵记号吓住。三部分分别表示：

1. 第一项衡量数据偏离模型均值有多远，并按系统发育协方差校正；
2. $\log |\mathbf{V}|$ 惩罚过分宽松的方差结构，防止模型只靠“把不确定性放得很大”解释一切；
3. 最后一项是正态分布的归一化常数。

若每个物种还有已知测量误差方差 s_i^2 ，最简单的处理是在协方差矩阵对角线上加它：

$$\mathbf{V}_{\text{总}} = \mathbf{V}_{\text{演化}} + \text{diag}(s_1^2, \dots, s_n^2).$$

不处理测量误差，会把观测噪声误当成演化速率。

M.6.4 两个后代怎样加权祖先值

设两个后代的观测为 x_1, x_2 ，它们从共同祖先到末端的布朗方差分别为 v_1, v_2 。该祖先的最大似然估计是逆方差加权平均：

$$\hat{x}_A = \frac{x_1/v_1 + x_2/v_2}{1/v_1 + 1/v_2}.$$

若 $x_1 = 10, v_1 = 1, x_2 = 14, v_2 = 3$ ，则：

$$\hat{x}_A = 11.$$

它不是简单平均 12。第一条枝累积方差较小，对祖先状态的信息更精确，因此权重更大。这是“平方变化最小化”与高斯似然之间的联系。

M.6.5 OU 模型增加了什么

OU 过程写成：

$$dX_t = \alpha(\vartheta - X_t)dt + \sigma dW_t.$$

给定祖先值 $X_0 = x_0$ ，长度 t 后：

$$E(X_t | x_0) = \vartheta + (x_0 - \vartheta)e^{-\alpha t},$$

$$\text{Var}(X_t | x_0) = \frac{\sigma^2}{2\alpha} (1 - e^{-2\alpha t}).$$

第一式说祖先影响以 $e^{-\alpha t}$ 衰减；第二式说方差不会无限增长，而趋向 $\sigma^2/(2\alpha)$ 。最容易解释的参数是半衰期：

$$t_{1/2} = \frac{\log 2}{\alpha}.$$

半衰期远长于树高时，数据很难把 OU 与布朗运动区分；半衰期极短时，深层祖先信息迅速被抹去。令

$\alpha \rightarrow 0$ ，OU 的均值和方差分别趋近布朗运动的 x_0 与 $\sigma^2 t$ 。

因此，估计出一个非零 α 并不自动证明存在自然选择。OU 是一个随机过程模型；“选择”“约束”或“适应峰”还需要独立生物学证据与合适的模型比较。

M.7 DEC 数学：范围状态、枝上变化和分支继承

M.7.1 范围为什么是一个状态

有 m 个地区时，一个物种的范围是地区集合，例如 $\{A\}$ 、 $\{B\}$ 、 $\{A, B\}$ 。若允许所有非空组合：

$$K = 2^m - 1.$$

若限制最多占据 $r_{\max}$ 个地区：

$$K = \sum_{r=1}^{r_{\max}} \binom{m}{r}.$$

这就是为什么 5 个地区和 15 个地区不是同一规模的问题。范围不是把每个地区独立做一次二元性状重建，因为地区之间的组合、扩散连通性和分支继承规则都相互依赖。

M.7.2 DEC 的枝上速率矩阵

设当前范围为 R 。一种常见构造是只允许一次增加或删除一个地区：

$$\begin{aligned} q_{R, R \cup \{b\}} &= d g(R, b), & b \notin R, \\ q_{R, R \setminus \{a\}} &= e h(R, a), & a \in R, |R| > 1. \end{aligned}$$

d 是范围扩张的基础速率， e 是某地区从范围中局部消失的基础速率； g, h 可以编码距离、连通性、环境或状态依赖修饰。对角线仍然是该行所有离开速率的负和。

这里的 e 不等于整条物种谱系死亡。若范围从 $\{A, B\}$ 变成 $\{A\}$ ，物种仍存在，只是在 B 地区局部消失。只有范围变为空集时才会触及“整条谱系不再存在”的问题，而标准固定树 DEC 通常不把空范围作为普通可见状态传播。

沿枝传播仍然是：

$$P(t) = e^{Qt}.$$

所以 DEC 的枝上部分与 Mk 在数学上共享连续时间马尔可夫链，只是状态空间和允许变化不同。

M.7.3 分支事件为何需要另一个张量

在观察到的分支节点，祖先范围 i 可能以多种方式由两个女儿范围 j, k 继承。定义原始权重 $w_{i,j,k}$ ，则条件概率可写成：

$$C_{i,j,k} = \frac{w_{i,j,k}}{\sum_{j',k'} w_{i,j',k'}}.$$

对固定的祖先范围 i ，所有允许分支结果的 C 之和为 1。它回答的是：既然此处已经有一个观察到的分支，哪种范围继承方式更可能？

假设祖先范围为 $\{A, B\}$ ，为演示只保留三种候选分支，原始权重分别为 1、1、2。归一化后：

$$C = (0.25, 0.25, 0.50).$$

但这还不是分支历史的后验。若左右后代数据对三个候选的条件似然乘积分别是 0.1、0.2、0.9，则未归一化后验贡献为：

$$(0.25 \times 0.1, 0.25 \times 0.2, 0.50 \times 0.9) = (0.025, 0.05, 0.45).$$

归一化后约为：

$$(0.048, 0.095, 0.857).$$

所以“模型先验上允许某类分支”与“数据支持这次具体分支属于该类”不是一回事。

M.7.4 分支事件后验怎样合并全树信息

若 $B_L(j)$ 、 $B_R(k)$ 是左右子树从分支起始状态 j, k 得到的似然， $O_v(i)$ 是节点上方信息，则：

$$P(i, j, k \mid D) \propto O_v(i) C_{i,j,k} B_L(j) B_R(k).$$

对所有允许的 (i, j, k) 归一化，才得到该节点各种祖先范围与分支方式的联合后验。只报告最优祖先范围会丢失“同一祖先范围下有多种继承历史”的不确定性。

DEC 的核心思想与原始似然框架可参见 Ree 与 Smith（2008）。不同软件对分支类型、方向、权重和根条件的定义并不完全相同，比较结果前必须核对实现约定。

M.8 SSE 数学：为什么灭绝侧枝会变成常微分方程

M.8.1 固定树方法缺失了哪一层随机过程

固定树 Mk 或 DEC 的基本问题是：

$$P(D_{\text{性状或范围}} \mid T, \theta).$$

树 T 已经给定。SSE 还为树的生成过程赋予概率：

$$P(D, T \mid \lambda, \mu, Q, \rho, \dots).$$

于是每条尚未观察的谱系在短时间内可能：保持不变、改变状态、分化、灭绝，或者产生最终没有被采样的后代。那些看不见的侧枝不能逐条枚举，因为数目和形状都未知；SSE 用概率函数把它们全部求和掉。

M.8.2 在一个极短时间内列出全部事件

令时间 t 从现在向过去增加。一个状态为 i 的谱系，在长度 Δt 的短时间段内有：

事件	一阶概率	对“没有采样后代”概率的后续贡献
无事件	$1 - r_i \Delta t$	$E_i(t)$
整条谱系灭绝	$\mu_i \Delta t$	1
状态变为 ℓ	$q_{i\ell} \Delta t$	$E_\ell(t)$
分化为状态 j, k 两支	$\lambda_{i,j,k} \Delta t$	$E_j(t)E_k(t)$

其中总事件率是：

$$r_i = \mu_i + \sum_{\ell \neq i} q_{i\ell} + \sum_{j,k} \lambda_{i,j,k}.$$

把互斥事件相加：

$$E_i(t + \Delta t) = (1 - r_i \Delta t) E_i(t) + \mu_i \Delta t + \sum_{\ell \neq i} q_{i\ell} \Delta t E_\ell(t) + \sum_{j,k} \lambda_{i,j,k} \Delta t E_j(t) E_k(t) + o(\Delta t).$$

两边减去 $E_i(t)$ ，除以 Δt ，再令 $\Delta t \rightarrow 0$ ：

$$\frac{dE_i}{dt} = \mu_i - r_i E_i + \sum_{\ell \neq i} q_{i\ell} E_\ell + \sum_{j,k} \lambda_{i,j,k} E_j E_k.$$

这就是常微分方程出现的原因。它不是为了让模型显得高级，而是“短时间事件表”在连续时间极限下的直接结果。

非线性项 $E_j E_k$ 来自一次分化后，两条女儿谱系都必须没有采样后代。两个概率相乘，所以方程不再是普通线性马尔可夫传播。

M.8.3 观测子树似然函数 $D_i(t)$

$D_i(t)$ 表示距今 t 的状态 i 谱系产生当前这部分观测子树的条件似然。在没有观察到分支节点的一小段枝上：

$$\frac{dD_i}{dt} = -r_i D_i + \sum_{\ell \neq i} q_{i\ell} D_\ell + \sum_{j,k} \lambda_{i,j,k} (D_j E_k + E_j D_k).$$

最后一项最关键。未观察的分化可以发生，只要一条女儿谱系产生观测子树，另一条最终没有采样后代：

$$D_j E_k + E_j D_k.$$

这就是所谓“把幽灵谱系纳入似然”的精确含义。模型通常不会告诉你某条具体灭绝侧枝叫什么、何时分了几叉；它计算的是所有这类不可见可能性的总概率贡献。

在一个确实观察到的二叉分支节点，两边都对应已采样子树，因此更新为：

$$D_i(t_{\text{node}}) = \sum_{j,k} \lambda_{i,j,k} D_{L,j}(t_{\text{node}}) D_{R,k}(t_{\text{node}}).$$

论文和软件可能把左右女儿视为有序或无序，因此会出现系数 2、转置或求和范围的差别。判断公式是否一致时，应比较事件定义，而不应只比较表面系数。

M.8.4 现在时边界条件

若状态 i 的现生谱系以概率 ρ_i 被采样：

$$E_i(0) = 1 - \rho_i.$$

对一个已采样且观测状态为 x 的末端，最简单的边界是：

$$D_i(0) = \begin{cases} \rho_i, & i = x, \\ 0, & i \neq x. \end{cases}$$

若末端状态有误差或缺失，0/1 指示可替换为观测发射概率。不同研究还可能对“至少采到一个后代”“冠群起源”或“根存活”作条件化，因此最终似然常数并不总能跨软件直接比较。

M.8.5 简单 BiSSE 是上式的特例

若分化后两个女儿都继承母系状态， $\lambda_{i,j,k}$ 只有 $j = k = i$ 时非零，则：

$$\frac{dE_i}{dt} = \mu_i - (\lambda_i + \mu_i + q_{ii})E_i + q_{ii}E_i + \lambda_i E_i^2.$$

相应的枝上观测子树似然为：

$$\frac{dD_i}{dt} = -(\lambda_i + \mu_i + q_{ii})D_i + q_{ii}D_i + 2\lambda_i E_i D_i.$$

最后一项中的 2 不是额外参数。一次分化后，可以是左女儿产生观测子树、右女儿不可见，也可以反过来；两种互斥情况在这个对称特例中贡献相同。

这正是 BiSSE 类方程的基本形状。Maddison、Midford 与 Otto (2007) 把二元性状变化和状态依赖的物种形成、灭绝放入同一个树生成似然中；后续 MuSSE、QuaSSE、GeoSSE、ClasSSE 与 HiSSE 扩展的是状态空间、分支继承或隐藏因素，而不是推翻这一概率骨架。

M.8.6 ODE 求解器到底近似了什么

解析解通常不存在，软件便沿每条枝数值积分 D, E 方程。求解器容差控制的是局部数值误差估计，不是生物学不确定性。一个实用复核是：

1. 把相对和绝对容差收紧一个数量级；
2. 重新计算对数似然、梯度和参数估计；

3. 若结论明显变化，当前数值精度不足，或参数区间存在刚性、边界和不可辨识问题。

“ODE 成功返回”只说明数值积分完成，不说明 SSE 模型能由这份数据可靠识别。

M.9 参数不确定性、模型比较和模型平均

M.9.1 点估计为何不够

最大似然给一个峰顶 $\hat{\theta}$ ，但不告诉读者峰有多宽。两个模型可能有相近峰值，却有完全不同的不确定性。常见表达包括轮廓似然区间、参数自助法分布和贝叶斯可信区间。

对关注参数 ψ ，把其余参数 η 在每个 ψ 下重新优化：

$$\ell_p(\psi) = \max_{\eta} \ell(\psi, \eta).$$

这叫轮廓似然。若曲线在很宽范围内几乎一样高，报告很多小数位没有意义。

M.9.2 AIC 在权衡什么

$$AIC = 2k - 2 \log \mathcal{L}(\hat{\theta}),$$

其中 k 是估计参数数目。第二项奖励拟合，第一项惩罚复杂度。定义：

$$\Delta_m = AIC_m - \min_r AIC_r,$$

可计算相对权重：

$$w_m = \frac{e^{-\Delta_m/2}}{\sum_r e^{-\Delta_r/2}}.$$

这些权重是在候选模型集和相应假设下的相对支持，不是“模型为真的概率”。如果所有候选模型都遗漏了关键过程，AIC 仍会选出其中一个第一名。

小样本修正版为：

$$AICc = AIC + \frac{2k(k+1)}{n-k-1}.$$

但系统发育数据中的有效样本量 n 并不总等于物种数，尤其在复杂 SSE 和范围模型中需遵循方法论文或软件定义，不能机械套公式。

M.9.3 模型平均比“选冠军”多做了一步

若模型 m 下某祖先状态的概率为 p_m ，AIC 权重模型平均为：

$$\bar{p} = \sum_m w_m p_m.$$

贝叶斯模型平均则使用模型后验：

$$P(X_v = i | D) = \sum_m P(X_v = i | D, M_m) P(M_m | D).$$

两者思想相同：不要把模型选择的不确定性假装成 0。但模型平均无法补回候选集中根本没有的过程。

M.9.4 模型比较不等于模型检验

“A 比 B 好”只是在两个候选之间比较。模型适合度还需问：从拟合模型模拟的数据，是否能再现真实数据的关键特征？

一般流程是：

$$\hat{\theta}, D \rightarrow D^{sim} \rightarrow S(D^{sim}) \text{ 与 } S(D) \text{ 比较,}$$

其中 S 可为范围大小分布、状态转换数、树不平衡度、性状与多样化关联或其他针对研究问题的统计量。这一步称为参数自助法检验或后验预测检查，取决于参数从点估计还是后验抽取。

M.10 不可辨识性：不同机制为什么会产生相似结果

参数可估不等于参数可识别。若许多参数组合给出近乎相同的似然，优化器即使返回一个数字，也不代表数据真正区分了这些组合。

M.10.1 三类常见补偿

模型	容易互相补偿的量	表面现象
CTMC	速率与枝长	只要 qt 相近，转移概率就相近
DEC 类	扩散 d 、局部消失 e 、分支事件权重	不同事件组合都能解释相似末端范围
SSE	物种形成 λ 、灭绝 μ 、取样率 ρ	不同隐藏历史产生相似现生树
OU	回归强度 α 、随机波动 σ 、根状态或长期中心	短树上多个过程给出相似协方差

M.10.2 四个诊断信号

1. 参数估计贴在允许边界，如 0 或预设上限；
2. 从不同初值优化得到差异很大的参数，但似然几乎相同；
3. 轮廓似然很平，或参数后验高度相关、长尾明显；
4. 用已知参数模拟数据后，分析流程也无法把参数恢复回来。

第 4 条最有说服力。模拟恢复不是为了证明现实模型为真，而是先确认“在模型自己生成的数据上，这套数据规模和分析流程至少有能力回答该问题”。

M.10.3 一个应始终报告的分层结果

将结论分成三层：

- 稳健层：跨树、跨模型、跨先验或约束仍一致；
- 模型依赖层：只有某些合理模型下成立；
- 不可识别层：数据不能可靠区分，应报告不确定而非强行讲故事。

这比只给一棵彩色祖先树更接近科学推断的真实内容。

M.11 一张公式阅读地图

研究问题	输入	数学核心	主要输出	最常见误读
离散祖先性状	固定树、末端状态	$P(t) = e^{Qt}$ 与树上剪枝	节点后验、速率、随机历史	把边缘节点众数拼成唯一历史
连续祖先性状	固定树、末端数值	高斯过程与系统发育协方差	祖先均值、区间、过程参数	把 OU 参数直接解释成选择证据
祖先分布	固定树、末端范围	范围 CTMC、 $C_{i,j,k}$ 、剪枝	节点范围、分支事件、范围历史	把局部消失 e 当谱系灭绝 μ
SSE	树、末端状态、取样模型	D_i, E_i 非线性 ODE	状态依赖的分化灭绝参数与节点状态	以为模型逐条复原了灭绝侧枝
联合贝叶斯分析	序列、树先验、性状或地理数据	似然乘先验并对参数和树积分	树、参数和祖先状态的联合后验	把单条最大可信树当全部后验

读任何新公式时，按以下顺序翻译：

- 1. 对象：它描述节点、枝上历史，还是树的生成？
- 2. 条件：树、参数、取样率和根分布中哪些被固定？
- 3. 消元：哪些未知量被求和或积分掉了？
- 4. 单位：这是概率、密度、无量纲权重，还是每单位时间速率？
- 5. 归一化：它目前是似然贡献，还是已经和为 1 的后验？

只要能逐项回答，公式就不再是一串符号。

M.12 手算练习与答案

这些练习只覆盖理解模型所需的数学，不要求手算大矩阵或实现 ODE 求解器。

练习 1：速率与等待时间

某状态离开速率为 0.25/百万年。保持该状态 2 百万年且没有任何离开事件的概率是多少？平均等待时间是多少？

答案。

$$P(N = 0) = e^{-0.25 \times 2} = e^{-0.5} \approx 0.6065.$$

平均等待时间为 $1/0.25 = 4$ 百万年。

练习 2：去向概率

某状态可以以速率 0.2 变为 B，以速率 0.3 变为 C。已知下一次离开一定发生，去 B 和 C 的概率各是多少？

答案。总离开速率为 0.5，因此：

$$P(B \mid \text{离开}) = 0.2/0.5 = 0.4, \quad P(C \mid \text{离开}) = 0.6.$$

练习 3：节点似然与节点后验

某节点红、蓝状态的下方似然分别为 0.12 和 0.08，上方信息分别为 0.1 和 0.4。节点后验是多少？

答案。未归一化贡献为 (0.012, 0.032)，总和 0.044，因此：

$$P(\text{红} \mid D) \approx 0.273, \quad P(\text{蓝} \mid D) \approx 0.727.$$

仅把 0.12 和 0.08 归一化会得到错误的 0.6 对 0.4，因为忽略了树上其余数据。

练习 4：范围状态数

有 8 个地区，最多允许范围包含 3 个地区，并排除空范围。共有多少个状态？

答案。

$$K = \binom{8}{1} + \binom{8}{2} + \binom{8}{3} = 8 + 28 + 56 = 92.$$

若不限制最大范围，则有 $2^8 - 1 = 255$ 个状态。

练习 5：DEC 局部消失

范围 $\{A, B, C\} \rightarrow \{A, C\}$ 是什么事件？这是否意味着物种灭绝？

答案。这是 B 地区从物种范围中局部消失。谱系仍占据 A、C，因此不是整条物种谱系灭绝。

练习 6: SSE 的幽灵侧枝

在 D_i 方程中，为什么分化项是 $D_j E_k + E_j D_k$ ，而不是只有 $D_j D_k$ ？

答案。沿一条没有观察到分支节点的枝，分化仍可能暗中发生：一支产生当前观测子树，另一支没有任何已采样后代。 $D_j D_k$ 对应两边都被观察到，应在实际观察到的分支节点更新中出现。

练习 7: OU 半衰期

若 $\alpha = 0.1/\text{百万年}$ ，祖先偏离长期中心的影响减半需要多久？

答案。

$$t_{1/2} = \log 2 / 0.1 \approx 6.93 \text{ 百万年}.$$

应再把它与树高比较；脱离树的时间尺度单独解释 α 没有意义。

练习 8: AIC 权重

两个模型的 AIC 分别为 100 和 104。忽略其他模型，它们的相对权重约是多少？

答案。 $\Delta = (0, 4)$ ，未归一化权重为 $(1, e^{-2}) \approx (1, 0.1353)$ ，归一化后约为：

$$(0.881, 0.119).$$

这不是说第一个模型有 88.1% 概率为真，只表示在当前候选集和 AIC 近似下的相对支持。

M.13 哪些数学细节可以暂时不学

若目标是正确选择、运行和解释祖先重建方法，暂时不必深入：

- 矩阵指数的 Jordan 标准形证明；
- Padé 逼近、尺度平方算法和一致化算法的误差证明；
- 自适应 Runge-Kutta、BDF 与刚性判据的全部实现细节；
- 多元正态积分、Hessian 渐近理论和马尔可夫链蒙特卡洛遍历性的完整证明。

但以下内容不能跳过：条件概率、似然与后验的区别；速率和概率的单位；剪枝求和；边缘与联合历史；DEC 的局部消失和 SSE 的谱系灭绝；取样率；参数与树不确定性；模型充分性与可辨识性。

对于软件开发人员，上述“可暂时不学”的内容会在实现数值内核时重新变成必修课；对于方法使用者，先掌握概率对象和生物学假设，收益远高于先钻进求解器细节。

M.14 模拟训练怎样近似祖先状态概率

前面的剪枝和 ODE 都以“能够计算似然”为前提。有些复杂模型可以向前模拟，却很难把所有隐藏历史求和成可处理的似然。这时可以先模拟大量“树、末端数据、真实祖先状态”，再训练分类器学习从观测资料到祖先状态的映射。

第 m 次训练模拟可写成：

$$\theta^{(m)} \sim p_{\text{训练}}(\theta), \quad (T^{(m)}, D^{(m)}, X^{(m)}) \sim p(T, D, X \mid \theta^{(m)}, M).$$

模拟器知道内部节点真状态 $X^{(m)}$ 。树和末端状态经过编码成为输入 $Z^{(m)}$ ，神经网络对节点 v 和候选状态 s

输出分数 $z_{v,s}$ 。softmax 把分数归一化：

$$\hat{p}_{v,s} = \frac{\exp(z_{v,s})}{\sum_r \exp(z_{v,r})}.$$

若全部训练节点标签共 B 个，第 b 个节点的真状态为 y_b ，常用交叉熵损失为：

$$J(\phi) = -\frac{1}{B} \sum_{b=1}^B \log \hat{p}_{b,y_b},$$

其中 ϕ 是网络权重。给真实状态越高概率，损失越小。

在无限模拟、网络容量足够且训练成功的理想条件下，分类器逼近的是：

$$\hat{p}_{v,s} \approx P_{\text{训练}}(X_v = s \mid Z).$$

关键是下标“训练”。参数抽样范围、根状态频率、树大小、取样方式和模拟器共同定义了这个概率。神经网络没有摆脱模型与先验，只是把它们放进了训练分布。

这种方式称为**摊销式推断**：先花较大成本训练，随后对许多同类数据快速预测。它与精确似然的关系可概括为：

情况	更合理的基线	原因
Mk、DEC 等似然可稳定计算	剪枝或 ODE 的精确/受控数值结果	可直接核查概率对象和误差
生成模型可模拟但似然难处理	模拟训练可作为探索路线	将大量计算提前到训练阶段
真实数据超出训练范围	两者都不能直接保证可靠	神经网络尤其可能无声外推

所以必须在独立模拟资料上检查分类正确率、概率校准和区间覆盖率，并改变训练参数分布做敏感性分析。只在训练集上损失很低，不代表真实数据上的祖先概率可信；模型错误时，网络可以非常精确地近似一个错误答案。

本章小结

祖先重建主干方法看似分散，其实只是在组合几种重复出现的操作：

短时间事件率 → 枝上传播 → 节点合并 → 对隐藏量求和或积分 → 似然或后验

- Mk 和 DEC 用矩阵指数传播有限状态变化；
- 布朗运动和 OU 用高斯转移分布传播连续性状；
- 树上剪枝避免枚举所有祖先组合；
- 随机映射在给定末端数据后抽取完整枝上历史；
- SSE 用 $E(t)$ 把无采样后代的隐藏谱系求和，并用 $D(t)$ 传播观测子树似然；
- 贝叶斯积分、模型平均和模拟检查继续处理参数、树、模型与适合度不确定性。
- 模拟训练用神经网络近似训练分布下的条件概率，速度优势不能替代分布外检查与校准。

理解这条主线后，遇到新软件时最重要的问题不再是“它用了多复杂的算法”，而是“它对什么随机对象建模、对哪些未知量求和、哪些条件仍被固定”。这才是判断方法是否真正比现有 BGB 引擎多回答了一个科学问题的标准。

精选延伸阅读

以下资料足够把本册的数学骨架追溯到原始方法和现代综述；完整的 194 条资料目录见全书参考文献。

1. Revell, L. J. 2025. 祖先表型性状重建现代综述。DOI
 2. Felsenstein, J. 1981. 系统发育似然与树上剪枝的经典论文。DOI
 3. Harmon, L. J. 2019. *Phylogenetic Comparative Methods*, BM、OU、Mk 与模型比较的开放教材。网页
 4. Ree, R. H. & Smith, S. A. 2008. DEC 范围演化与分支继承似然。DOI
 5. Maddison, W. P., Midford, P. E. & Otto, S. P. 2007. BiSSE 原始方法。DOI
 6. FitzJohn, R. G. 2012. **diversitree** 与 SSE 计算框架。DOI
 7. Burnham, K. P. & Anderson, D. R. 2002. AIC、模型权重和模型平均专著。DOI
 8. Ho, L. S. T. & Dinh, V. 2022. 祖先状态何时可以一致恢复的统一理论。DOI
 9. Landis, M. J. & Thompson, A. 2025. 模拟训练的系统发育深度学习框架 phyddle。DOI
 10. Nagel, A. A. & Landis, M. J. 2026. 深度学习离散祖先状态重建预印本。DOI
-

最后一页：只记住这八句话

1. 似然固定数据比较参数，后验用数据更新未知量。
2. 速率乘以时间才决定一条枝积累了多少变化机会。
3. 剪枝是在局部求和，不是挑一套祖先状态硬拼起来。
4. 节点边缘概率不是完整历史；事件次数要从历史分布计算。
5. DEC 的范围局部消失与 SSE 的整谱系灭绝是不同事件。
6. SSE 的 $E(t)$ 不是一棵复原出的幽灵树，而是所有无采样后代历史的总概率。
7. 更复杂的模型只会增加可表达机制，不会自动增加数据中的信息。
8. 精确似然、贝叶斯采样和神经网络预测都必须接受模型错设与模拟校准检查。